

LAPORAN TEKNIS KOMPREHENSIF

CAPSTONE PROJECT



ID Tim: CC26-PSU167
Tema: Fintech untuk Generasi Muda

Nama Anggota Tim	Peran
Umar Andika Fatihariz	AI Engineer
Syamaidzar Alisandaru Ar Rozin	AI Engineer
Fanidyasani Atantya Winayaka Purba	Data Scientist
Patricia Audrey Roellina	Data Scientist
Ahmad Zidan	Full-Stack Web Developer
Arifin Ihsan Nugroho	Full-Stack Web Developer

2024 / 2025

BAB 1 — PROBLEM DISCOVERY

1.1 Latar Belakang Masalah

Penggunaan QRIS dan dompet digital (e-wallet) yang semakin meluas telah mengubah cara masyarakat, terutama generasi muda, dalam melakukan transaksi. Pembayaran digital menawarkan proses yang lebih cepat dan praktis dibandingkan metode manual, sehingga penggunaannya terus meningkat. Namun, di balik kemudahan tersebut terdapat berbagai tantangan yang dapat memengaruhi perilaku dan pengelolaan keuangan pengguna. Berdasarkan hasil observasi, beberapa permasalahan utama yang ditemukan adalah sebagai berikut.

- **Meningkatnya Fenomena Leakage Spending:** Kemudahan transaksi digital mendorong terjadinya banyak pengeluaran kecil (micro-transactions) yang sering kali tidak disadari dan tidak tercatat dengan baik. Berdasarkan hasil analisis, sebanyak 78,4% dari total 6.573 transaksi memiliki nilai di bawah Rp100.000, dengan akumulasi pengeluaran mencapai Rp328.752.967. Temuan ini menunjukkan bahwa kebocoran keuangan (*financial leakage*) umumnya berasal dari transaksi bernilai kecil yang terjadi secara berulang, sehingga dapat mengurangi kemampuan menabung dan berdampak pada kesehatan finansial pengguna.
- **Keterbatasan Pencatatan Keuangan Konvensional:** Sebagian besar aplikasi keuangan masih mengandalkan input manual, sehingga pengguna harus mencatat transaksi satu per satu. Proses ini sering dianggap merepotkan dan menyebabkan pencatatan tidak dilakukan secara konsisten.
- **Potensi Financial Anxiety:** Kurangnya pemantauan terhadap pengeluaran membuat pengguna sulit memahami kondisi keuangannya secara menyeluruh. Akibatnya, muncul kekhawatiran ketika pengeluaran terasa lebih besar dari yang diperkirakan.
- **Kebutuhan Solusi yang Lebih Proaktif:** Pelacakan pengeluaran saja tidak cukup untuk mengatasi kebocoran finansial. Diperlukan sistem yang mampu mengenali pola pengeluaran, memberikan peringatan dini, dan membantu pengguna mencegah masalah keuangan sebelum terjadi.

1.2 Tujuan Proyek

Tujuan Utama: Menciptakan Walle sebagai suatu platforma yang tidak hanya sekadar "Tracking", namun mengubahnya menjadi "Predicting & Preventing" (meramal dan mencegah kebocoran).

Dengan pendekatan ini, pengguna tidak lagi sekadar melihat ke belakang (laporan historis), melainkan mendapat gambaran ke depan yang actionable untuk mengendalikan keuangan secara proaktif.

BAB 2 — BUSINESS UNDERSTANDING

2.1 Target Pengguna & Persona

Wallee dirancang untuk digunakan oleh siapa saja yang aktif melakukan transaksi digital, seperti menggunakan QRIS, e-wallet, mobile banking, atau pembayaran non-tunai lainnya. Platform ini tidak membatasi pengguna berdasarkan usia, pekerjaan, maupun tingkat pendapatan, karena setiap orang memiliki tantangan yang berbeda dalam mengelola keuangan.

- **Beragam Kondisi Keuangan Pengguna:** Pengguna Wallee dapat berasal dari berbagai latar belakang, mulai dari mahasiswa yang mengatur uang bulanan, pekerja yang harus membayar berbagai tagihan rutin, hingga individu dengan gaya hidup aktif yang sering melakukan transaksi harian. Setiap pengguna memiliki pola pengeluaran dan kebutuhan finansial yang berbeda.
- **Masalah yang Dihadapi Bersifat Universal:** Meskipun kondisi keuangan setiap orang berbeda, banyak pengguna menghadapi masalah yang sama, yaitu pengeluaran yang tidak disadari atau sulit dikontrol. Pengeluaran kecil yang terjadi berulang kali maupun pengeluaran besar yang tidak direncanakan dapat berdampak pada kesehatan keuangan jika tidak dikelola dengan baik.

2.2 Masalah Universal Pengguna Digital

Meskipun setiap pengguna memiliki profil keuangan yang unik, terdapat pola masalah yang bersifat universal di kalangan pengguna instrumen pembayaran digital:

Tantangan	Deskripsi	Relevansi Data
Micro-spending Blindspot	Pengeluaran kecil berulang (<Rp100K) yang tidak terasa secara individual namun signifikan secara kumulatif	78,4% transaksi bernilai <Rp100K dalam dataset (5.154 dari 6.573 transaksi)
Kategori Dominan Tidak Disadari	Pengguna seringkali tidak menyadari kategori pengeluaran mana yang paling menguras anggaran	Transport (20,2%) dan Kebutuhan Rumah (24,3%) mendominasi total pengeluaran
Seasonal Spending Spike	Lonjakan pengeluaran pada periode tertentu (akhir/awal bulan, musim liburan) yang tidak diantisipasi	Pengeluaran tertinggi terjadi di bulan Desember (Rp64,6 juta)
Digital Payment Over-reliance	Dominasi metode pembayaran digital memperkuat payment decoupling dan menurunkan sadar pengeluaran	66,8% transaksi menggunakan metode digital (GoPay, DANA, OVO, QRIS)

2.3 Value Proposition Data Science

Dari Pandangan Data Science, Wallee diposisikan sebagai sistem yang mengubah data transaksi mentah menjadi *actionable financial intelligence* yang dapat digunakan untuk pengambilan keputusan. Transformasi ini dilakukan melalui tiga lapisan nilai utama:

- **Layer 1 — Descriptive Intelligence** Mengonversi ribuan data transaksi menjadi ringkasan kondisi keuangan yang mudah dipahami, seperti skor kesehatan finansial, kategori pengeluaran utama, dan tren pengeluaran bulanan.
- **Layer 2 — Predictive Intelligence:** Memanfaatkan model *time-series forecasting* untuk memprediksi tren pengeluaran di masa mendatang berdasarkan pola historis, sehingga pengguna dapat melakukan perencanaan anggaran secara lebih proaktif.
- **Layer 3 — Prescriptive Intelligence:** Menggabungkan hasil *anomaly detection* dan *forecasting* untuk menghasilkan rekomendasi tindakan yang konkret, terukur, dan berbasis data guna membantu pengambilan keputusan finansial.

2.4 Pertanyaan Bisnis

Untuk memastikan proses analisis data tetap berfokus pada tujuan yang ingin dicapai, tim Data Science menetapkan 3 pertanyaan bisnis utama berikut:

No.	Pertanyaan Bisnis	Dimensi Analitik
BQ-1	Bagaimana distribusi dan tren pengeluaran mikro (<Rp100.000) di seluruh kategori, dan seberapa besar kontribusinya terhadap total kebocoran finansial?	Deskriptif & Temporal
BQ-2	Kategori pengeluaran apa yang mendominasi kontribusi total belanja pengguna, dan pada periode apa lonjakan pengeluaran paling sering terjadi dalam siklus bulanan?	Komparatif & Temporal
BQ-3	Metode pembayaran digital apa yang paling dominan digunakan, dan bagaimana hubungannya dengan pola pengeluaran pengguna aktif?	Segmentasi & Korelasi

BAB 3 — DATA UNDERSTANDING DAN DATA WRANGLING

3.1 Sumber Data & Data Gathering

Data transaksi keuangan merupakan informasi yang bersifat pribadi sehingga tidak dapat diperoleh secara langsung tanpa persetujuan dari pemilik data. Oleh karena itu, proyek ini menggunakan pendekatan *Synthetic Behavioral Generation*, yaitu pembuatan data sintesis yang meniru pola perilaku transaksi nyata berdasarkan kebiasaan generasi muda Indonesia.

Proses pengumpulan data dan perancangan dataset dilakukan secara bertahap melalui tiga komponen utama yang saling melengkapi.

3.1.1 Pemetaan Atribut & Arsitektur Data (Dataset Referensi Eksternal)

Dataset utama yang digunakan dalam tahapan analisis, *feature engineering*, pemodelan, dan visualisasi pada proyek Wallee adalah dataset transaksi yang tersimpan dan dapat diakses secara terbuka melalui tautan Google Drive berikut:

- [Dataset Wallee](#)

Seluruh data yang tersedia di dalam tautan tersebut digunakan secara menyeluruh sebagai sumber data utama dalam proyek ini. Untuk mendukung prinsip transparansi, replikasi penelitian, dan validasi akademik, dataset utama tersebut disediakan dalam format .csv dan .xlsx.

Sementara itu, untuk menunjang proses perancangan struktur data, identifikasi atribut penting, dan pemahaman logika bisnis transaksi keuangan, dilakukan studi komparatif terhadap 3 dataset *open-source* dari platform Kaggle. Ketiga dataset ini bertindak murni sebagai **dataset referensi pendukung** (*blueprint*) untuk membangun logika data utama, bukan sebagai sumber data mentah yang dianalisis langsung. ketiga data set tersebut meliputi:

- [Personal Finance Dataset](#): digunakan sebagai acuan variabel pendapatan dan pengelompokan saldo.
- [Financial Transaction Description Dataset](#): digunakan untuk memahami variasi deskripsi transaksi mentah (*raw transaction strings*).
- [Personal Budget Transactions Dataset](#): digunakan sebagai referensi pola siklus anggaran bulanan dan *seasonal spending spike*.

3.1.2 Pengumpulan Data Kontekstual Lokal

Agar data sintesis lebih relevan dengan kondisi di Indonesia, dilakukan pengumpulan data pendukung melalui dua pendekatan:

- Web scraping referensi merchant: Pengambilan data dari berbagai platform e-commerce dan direktori merchant menggunakan pustaka Python seperti BeautifulSoup dan Requests, mencakup nama merchant, kategori, dan rentang harga yang realistis.

- Kurasi manual dan validasi kontekstual: Data hasil scraping kemudian dikurasi untuk memastikan kesesuaian dengan ekosistem transaksi digital Indonesia, termasuk penggunaan QRIS dan e-wallet.

F&B	Transportasi	Ritel & Minimarket	Lainnya
Mixue, Kopi Kenangan, Mie Gacoan, Es Teh Indo	Gojek, Grab, Trans Jogja	Indomaret, Alfamart, Miniso	Tokopedia, Shopee, berbagai merchant lokal lainnya

3.2 Data Assessing

Sebelum melakukan proses pembersihan data, dilakukan penilaian kualitas data (data assessment) secara sistematis menggunakan skrip pyhthon untuk mengidentifikasi berbagai permasalahan yang berpotensi memengaruhi hasil analisis. Berikut adalah kode asesmen yang digunakan:

```
# === SYSTEM MODULAR DATA ASSESSMENT PIPELINE ===

# 1. Validasi Data Finansial Pengguna (Dashboard Engine)
print("\nInfo personal_df:")
print(personal_df.info())
print("\nMissing values di personal_df:")
print(personal_df.isna().sum())
print("\nJumlah duplikasi:", personal_df.duplicated().sum())

# 2. Validasi Data Teks Eksperimental (NLP/Categorization Engine)
print("\nInfo nlp_df:")
print(nlp_df.info())
print("\nMissing values di nlp_df:")
print(nlp_df.isna().sum())
print("\nJumlah duplikasi:", nlp_df.duplicated().sum())

# 3. Validasi Data Deteksi Anomali (Core Engine)
print("\nInfo anomaly_df:")
print(anomaly_df.info())
print("\nMissing values di anomaly_df:")
print(anomaly_df.isna().sum())
print("\nJumlah duplikasi:", anomaly_df.duplicated().sum())

# 4. Validasi Data Referensi Lokal (Knowledge Base Scraping)
print("\nInfo data scraping (kb):")
print(kb.info())
print("\nMissing values di data scraping (kb):")
print(kb.isna().sum())
print("\nJumlah duplikasi:", kb.duplicated().sum())
```

Hasil asesmen mengidentifikasi empat kategori permasalahan utama:

Jenis Masalah	Deskripsi Temuan	Dampak Potensial
Inkonsistensi Kapitalisasi Teks	Penulisan nama merchant dan item tidak konsisten, seperti "MINISO", "Miniso", dan "miniso".	Menyebabkan <i>high-cardinality bias</i> karena sistem menganggap variasi penulisan tersebut sebagai entitas yang berbeda, sehingga jumlah kategori unik menjadi lebih besar dari kondisi sebenarnya.

Karakter Noise & Simbol	Adanya simbol seperti , +, -, dan karakter khusus pada deskripsi item	Mengganggu proses tokenisasi NLP dan meningkatkan dimensi vocabulary secara tidak perlu (curse of dimensionality)
Missing Values	Terdapat nilai kosong (<i>missing values</i>) pada beberapa kolom.	Berpotensi menimbulkan bias pada hasil analisis statistik maupun pemodelan prediktif.
Inkonsistensi Format Tanggal	Kolom date memiliki format string dan belum bertipe datetime	Menghambat proses ekstraksi fitur temporal, seperti bulan, hari, dan jam, serta membatasi analisis <i>time-series</i> .

3.3 Data Cleaning

Setelah permasalahan data berhasil diidentifikasi, dilakukan proses pembersihan data menggunakan Python untuk memastikan dataset siap digunakan pada tahap analisis. Tahapan pembersihan yang dilakukan meliputi:

3.3.1 Normalisasi Teks ke Lowercase

Kategori ini bertujuan untuk menyamakan format penulisan huruf agar seragam. Langkah ini mencegah sistem menganggap kata dengan perbedaan kapitalisasi sebagai entitas yang berbeda (high-cardinality bias).

```
# Normalisasi teks ke lowercase
df["merchant"] = df["merchant"].str.lower()
df["item"] = df["item"].str.lower()
df["kategori"] = df["kategori"].str.lower()
```

3.3.2 Regexp Cleaning

Kategori ini menggunakan *Regular Expression* (Regex) untuk mengeliminasi karakter non-alfanumerik serta mereduksi spasi berlebih yang dikategorikan sebagai gangguan (*noise*) dalam pemrosesan teks.

```
import re

# === KATEGORI 2: NOISE REDUCTION ===
# 1. Menghapus Karakter Non-Alfanumerik pada Kolom Asli
df["merchant"] = df["merchant"].apply(lambda x: re.sub(r"[^a-zA-Z0-9]", " ", str(x)))
df["item"] = df["item"].apply(lambda x: re.sub(r"[^a-zA-Z0-9]", " ", str(x)))

# 2. Mereduksi Spasi Berlebih (Extra Whitespaces)
df["merchant"] = df["merchant"].str.replace(r"\s+", " ",
regex=True).str.strip()
df["item"] = df["item"].str.replace(r"\s+", " ",
regex=True).str.strip()
```

3.3.3 Feature Engineering

Kategori ini menggabungkan dua atribut teks terpisah menjadi satu fitur baru bernama `combined_text` guna memperkaya muatan informasi kontekstual yang akan dibaca oleh sistem.

```
# === KATEGORI 3: FEATURE ENGINEERING ===
# 1. Penggabungan Konteks Atribut Teks
df["combined_text"] = df["merchant"] + " " + df["item"]
```

```
# 2. Sanitisasi Ulang pada Fitur Baru
df["combined_text"] = df["combined_text"].apply(lambda x:
re.sub(r"^[a-zA-Z0-9 ]", "", str(x)))
df["combined_text"] = df["combined_text"].str.replace(r"\s+", " ",
regex=True).str.strip()
```

3.3.4 Structural Data Cleaning (Handling Anomalies)

ini berfokus pada penanganan anomali struktural dataset melalui penghapusan data duplikat dan baris kosong (*missing values*) agar tidak menimbulkan bias dalam analisis.

```
# === KATEGORI 4: STRUCTURAL DATA CLEANING ===
# 1. Eliminasi Data Duplikat
df = df.drop_duplicates()

# 2. Eliminasi Nilai Kosong (Missing Values)
df = df.dropna()
```

3.3.5 Temporal Data Type Standardization & Serialization

Kategori ini melakukan transformasi tipe data string mentah menjadi objek waktu standar agar dapat diproses oleh pemodelan berbasis waktu, dilanjutkan dengan penyimpanan berkas akhir.

```
import pandas as pd

# === KATEGORI 5: DATA CASTING & SERIALIZATION ===
# 1. Konversi Tipe Data String ke Datetime
df["date"] = pd.to_datetime(df["date"])

# 2. Penataan Ulang Indeks Baris
df = df.reset_index(drop=True)

# 3. Validasi Akhir (Sanity Check)
print(df.head())
print(f"Shape: {df.shape} | Missing: {df.isnull().sum().sum()} |
Duplicates: {df.duplicated().sum()}")

# 4. Data Serialization (Export)
df.to_csv("preprocessed_finance_dataset.csv", index=False)
df.to_excel("preprocessed_finance_dataset.xlsx", index=False)
```

3.4 Dataset Akhir

Hasil: Dataset akhir yang diperoleh bersifat bersih (noise-free), terstruktur rapi, dan siap diinput ke tahap Exploratory Data Analysis serta Feature Engineering tanpa memerlukan preprocessing tambahan.

BAB 4 — EXPLORATORY DATA ANALYSIS (EDA)

Berdasarkan pertanyaan bisnis yang telah dirumuskan, dilakukan proses Exploratory Data Analysis (EDA) untuk mengidentifikasi pola, tren, dan karakteristik data. Temuan-temuan utama yang diperoleh dari analisis tersebut disajikan secara ringkas pada bagian berikut.

4.1 Distribusi Transaksi Mikro — Leakage Spending Analysis (BQ-1)

```
# Filter transaksi mikro (<Rp100.000) untuk persona anak kos & mahasiswa (2024-2025)
micro_df = df[(df["nominal"] < 100000) &
              (df["date"].dt.year.isin([2024, 2025]))]

# Agregasi total nominal dan jumlah transaksi per kategori
micro_analysis = micro_df.groupby("kategori").agg(
    total_nominal=("total_harga", "sum"),
    jumlah_transaksi=("total_harga", "count")
).reset_index()

print(micro_analysis.sort_values("total_nominal", ascending=False))
```

Kategori Pengeluaran	Total Nominal (Rp)	Jumlah Transaksi	Kontribusi Nominal (%)	Kontribusi Frekuensi (%)
Makanan & Minuman	Rp18.640.444	599	60,93%	60,08 %
Transport	Rp11.950.987	398	39,07%	39,92%

4.1.1 Analisis Komparatif Kategori Dominan

Berdasarkan hasil analisis, kategori Makanan & Minuman menjadi sumber utama *micro-spending* dengan kontribusi 60,39% dari total pengeluaran dan 60,08% dari total frekuensi transaksi. Sementara itu, kategori Transport menempati posisi kedua dengan total pengeluaran Rp11.950.987 dan 398 transaksi. Tingginya frekuensi transaksi pada kategori Makanan & Minuman menunjukkan bahwa pengeluaran konsumsi harian berpotensi menjadi sumber utama kebocoran keuangan jika tidak dikelola dengan baik.

4.1.2 Analisis Pola dan Fluktuasi Temporal Bulanan

Hasil dari analisis terhadap 2 kategori utama (makan & minum dan transportasi) menunjukkan karakteristik perilaku belanja yang berbeda:

- Makanan & Minuman:** Menunjukkan pola pengeluaran yang relatif stabil sepanjang periode pengamatan. Puncak pengeluaran terjadi pada April 2025 sebesar Rp973.710, sedangkan frekuensi transaksi tertinggi tercatat pada September 2025 sebanyak 32 transaksi. Pola ini mencerminkan kebutuhan konsumsi harian yang dilakukan secara rutin.
- Transportasi:** Menunjukkan pola pengeluaran yang lebih fluktuatif dibandingkan Makanan & Minuman. Pengeluaran tertinggi tercatat pada Juni 2024 sebesar Rp917.169 dan kembali meningkat pada September 2025 sebesar Rp906.629. Pola ini mengindikasikan bahwa kebutuhan mobilitas cenderung dipengaruhi oleh aktivitas tertentu dan tidak terjadi secara konsisten setiap bulan.

Insight Utama: Meskipun setiap transaksi bernilai di bawah Rp100.000, akumulasinya mencapai lebih dari Rp30,5 juta selama dua tahun pengamatan. Temuan ini menunjukkan

fenomena *micro-spending*, yaitu pengeluaran kecil yang secara individu terlihat tidak signifikan, tetapi memberikan dampak besar terhadap kondisi keuangan ketika terjadi secara berulang.

4.2 Analisis Kategori Transaksi per Persona & Waktu Lonjakan

```
# === AGREGASI PENGELUARAN PER KATEGORI (BQ-2) ===
category_analysis = df.groupby("kategori").agg(
    total_pengeluaran=("total_harga", "sum"),
    jumlah_transaksi=("total_harga", "count")
).reset_index()

# Menghitung persentase kontribusi pengeluaran
category_analysis["pct_pengeluaran"] = (
    category_analysis["total_pengeluaran"] /
    category_analysis["total_pengeluaran"].sum() * 100
)

# Mengurutkan berdasarkan pengeluaran terbesar
category_analysis =
category_analysis.sort_values("total_pengeluaran", ascending=False)
print(category_analysis)
```

Hasil analisis segmentasi pengeluaran per kategori:

Rank	Kategori Pengeluaran	Total Pengeluaran	Jumlah Transaksi	Kontribusi (%)
1	Kebutuhan Rumah	Rp165.964.388	942	24,3%
2	Transport	Rp137.512.436	1.113	20,2%
3	Belanja	Rp107.235.103	784	15,7%
4	Tagihan & Utilitas	Rp96.140.381	584	14,1%
5	Makanan & Minuman	Rp73.562.410	1.474	10,8%
6	Hiburan	Rp68.478.967	802	10,0%
7	Kesehatan	Rp25.812.022	577	3,8%
8	Pendidikan	Rp7.028.183	297	1,0%
-	TOTAL	Rp681.733.890	6.573	100%

Insight Utama: Kategori Kebutuhan Rumah (24,3%) dan Transport (20,2%) mendominasi pengeluaran secara nominal, sedangkan Makanan & Minuman mencatat frekuensi tertinggi dengan 1.474 transaksi dan kontribusi 10,8%. Temuan ini menunjukkan perbedaan antara nilai dan frekuensi transaksi yang menjadi dasar analisis Wallee.

4.3 Analisis Metode Pembayaran (Q4 2024)

```
# === ANALISIS PREFERENSI KANAL PEMBAYARAN (BQ-3) ===
# Memastikan kolom date bertipe datetime
dataset_df["date"] = pd.to_datetime(dataset_df["date"])

# Filter data: Q4 2024, Persona Gen-Z, Merchant Target, dan Non-Cash
df_q3 = dataset_df[
    (dataset_df["date"].dt.year == 2024)
    & (dataset_df["date"].dt.month.isin([10, 11, 12]))
    & (dataset_df["persona"].isin(["anak_kos", "mahasiswa",
    "anak_sultan"]))
    & (dataset_df["merchant"].str.lower().isin(["miniso", "gacoan"]))
    & (dataset_df["payment_method"].str.lower() != "cash")
].copy()

# Menghitung Top 3 metode pembayaran digital
top_3_payments = df_q3["payment_method"].value_counts().head(3)
print(top_3_payments)
```

Rank	Metode Pembayaran	Jumlah Transaksi	Jenis Klasifikasi
1	QRIS	26	Digital (QR Code)
1	GoPay	26	Digital (E-Wallet)
3	Debit Card	17	Non-Digital (Kartu)

Insight Utama: Dominasi penggunaan **metode pembayaran digital (nontunai)** menunjukkan bahwa transaksi *cashless* telah menjadi bagian penting dari kehidupan sehari-hari. Namun, kemudahan yang ditawarkan juga berpotensi mengurangi kesadaran terhadap pengeluaran, sehingga meningkatkan risiko terjadinya *leakage spending*.

BAB 5 — FEATURE ENGINEERING

Proses feature engineering dilaksanakan untuk memperkaya dimensi dataset dan meningkatkan kemampuan model Machine Learning dalam mengenali pola perilaku finansial yang kompleks.

5.1 Behavioral Features

memetakan profil transaksi pengguna berdasarkan tingkat pengeluaran dan jenis instrumen pembayaran yang digunakan.

```
# 1. SPENDING LEVEL
def spending_level(x):
    if x < 50000:
        return "low"
    elif x < 200000:
        return "medium"
    else:
        return "high"

df["spending_level"] = df["total_harga"].apply(spending_level)

# 11. PAYMENT DIGITAL FLAG
digital_methods = ["gopay", "ovo", "dana", "qris"]
df["is_digital_payment"] =
df["payment_method"].str.lower().isin(digital_methods).astype(
    int
)
```

Analisis Teknis:

- `spending_level`: Kategori low, medium, dan high digunakan untuk mengelompokkan tingkat pengeluaran sehingga memudahkan identifikasi pola micro-spending, yang berpotensi menjadi sumber kebocoran keuangan (leakage spending).
- `is_digital_payment`: Mengubah metode pembayaran menjadi format biner (0 dan 1) memungkinkan analisis kuantitatif terhadap hubungan antara penggunaan pembayaran digital dan pola pengeluaran pengguna.

5.2 Temporal Features

memecah data kolom date (Timestamp) menjadi komponen waktu yang lebih spesifik untuk melihat pola kebiasaan berdasarkan siklus waktu harian, mingguan, hingga bulanan.

```
# 2. TRANSACTION MONTH
df["month"] = df["date"].dt.month

# 3. TRANSACTION DAY
df["day_name"] = df["date"].dt.day_name().str.lower()

# 4. WEEKEND FLAG
df["is_weekend"] = (df["date"].dt.weekday >= 5).astype(int)

# 5. TRANSACTION HOUR & 6. TIME CATEGORY
df["hour"] = df["date"].dt.hour
```

```
def time_category(hour):  
    if 5 <= hour < 11:  
        return "morning"  
    elif 11 <= hour < 15:  
        return "afternoon"  
    elif 15 <= hour < 19:  
        return "evening"  
    else:  
        return "night"  
  
df["time_category"] = df["hour"].apply(time_category)
```

Analisis Teknis: Berdasarkan studi perilaku konsumen, aktivitas *impulse buying* memiliki keterkaitan erat dengan faktor waktu. Oleh karena itu, fitur `is_weekend` dan `time_category` diekstraksi untuk menganalisis apakah pengeluaran berlebih (*leakage spending*) lebih sering terjadi pada akhir pekan atau pada periode waktu tertentu, seperti jam makan siang dan malam hari.

5.3 Text Engineering

standarisasi teks (mengubah ke *lowercase*) serta mengekstrak informasi dari deskripsi item belanja.

```
# 7, 8, 9. TEXT MINING FEATURES & NORMALIZATION  
df["merchant"] = df["merchant"].str.lower()  
df["item"] = df["item"].str.lower()  
df["kategori"] = df["kategori"].str.lower()  
df["payment_method"] = df["payment_method"].str.lower()  
  
df["combined_text"] = df["merchant"] + " " + df["item"]  
df["item_length"] = df["item"].apply(len)  
df["word_count"] = df["combined_text"].apply(lambda x:  
len(x.split()))
```

Analisis Teknis: Tahap ini mencakup proses *data cleaning* melalui penyeragaman huruf kecil (*lowercasing*) untuk menghindari duplikasi kategori akibat perbedaan penulisan, seperti "GoPay" dan "gopay". Selain itu, fitur `combined_text` dan `word_count` dibuat sebagai tahap *pre-processing* guna mendukung pengembangan analisis berbasis *Natural Language Processing (NLP)*, seperti pengelompokan otomatis nama barang atau transaksi di masa mendatang.

Fitur-Fitur Baru yang Dikonstruksi

Nama Fitur	Tipe	Alasan & Fungsi
spending_level	Kategorikal	Mengelompokkan nilai transaksi ke dalam kategori rendah, sedang, dan tinggi untuk mempermudah analisis pola pengeluaran.
month	Temporal	Menangkap pola pengeluaran berdasarkan bulan dan tren musiman.
day_name	Temporal	Mengidentifikasi pola transaksi berdasarkan hari dalam seminggu.

hour	Temporal	Menganalisis kecenderungan transaksi berdasarkan waktu transaksi.
time_category	Temporal	Mengelompokkan transaksi ke dalam sesi pagi, siang, sore, dan malam untuk memahami perilaku harian pengguna.
is_weekend	Biner (0/1)	Membedakan transaksi pada hari kerja dan akhir pekan.
is_digital_payment	Biner (0/1)	Mengidentifikasi penggunaan metode pembayaran digital dan tingkat adopsinya.
item_length	Numerik	Mengidentifikasi penggunaan metode pembayaran digital dan tingkat adopsinya.
word_count	Numerik	Menghitung jumlah kata pada deskripsi item untuk mendukung pemrosesan teks (NLP).

5.2 Hasil Feature Engineering

Dataset Hasil: Proses *feature engineering* menghasilkan dataset yang lebih representatif terhadap perilaku transaksi pengguna. Fitur-fitur baru yang dibangun mencakup aspek temporal, pola pengeluaran, metode pembayaran, dan karakteristik teks, sehingga dataset siap digunakan pada tahap pemodelan Machine Learning.

BAB 6 — DASHBOARD DAN DEPLOYMENT

6.1 Pengembangan Dashboard Streamlit

Antarmuka pengguna dibangun menggunakan Streamlit untuk menyediakan aplikasi yang interaktif, mudah digunakan, dan mendukung integrasi langsung dengan pipeline data science serta model Machine Learning yang dikembangkan.

6.2 Fitur-Fitur Dashboard

Modul Fitur	Deskripsi Fungsional
Dashboard	Menampilkan indikator keuangan utama, termasuk skor kesehatan finansial, total transaksi, dan total pengeluaran. Sistem juga menganalisis pola pengeluaran, kategori dan merchant teratas, metode pembayaran dominan, serta memberikan ringkasan dan rekomendasi finansial berbasis AI untuk mendukung pengambilan keputusan keuangan yang lebih efektif.
Categorization	Mendeteksi dan mengelompokkan kategori pengeluaran secara otomatis berdasarkan input teks atau hasil pindai nota transaksi (misalnya mendeteksi "Gojek" ke dalam kategori <i>transport</i>).
Behavior Analysis	Menampilkan ringkasan kondisi keuangan pengguna melalui total pengeluaran, skor kesehatan finansial, serta label perilaku keuangan berbasis AI (<i>Healthy Spending Behaviour</i>). Informasi tersebut didukung oleh visualisasi interaktif yang mencakup grafik distribusi pengeluaran per kategori (<i>User Spending by Category</i>), grafik tren pengeluaran harian (<i>Spending by Day</i>), serta daftar transaksi terbaru (<i>Recent Transactions</i>) untuk memberikan pemahaman yang lebih komprehensif terhadap pola pengelolaan keuangan pengguna.

6.3 Deployment & Akses Publik

Aplikasi Wallee telah berhasil di-deploy secara publik melalui platform Streamlit Cloud dan dapat diakses melalui tautan berikut:

Link Aplikasi Wallee (Publik):

<https://walleedashboard.streamlit.app/>

Platform : Streamlit Cloud

Status : Live / Aktif

Akses : Publik

BAB 7 — KESIMPULAN DAN REKOMENDASI ACTION ITEMS

7.1 Kesimpulan Analitis

Berdasarkan seluruh tahapan *Data Science Lifecycle* yang telah dilaksanakan—mulai dari *Problem Discovery*, *Data Wrangling*, *Exploratory Data Analysis* (EDA), *Feature Engineering*, hingga *Advanced Analytics*—berikut adalah kesimpulan analitis yang diperoleh:

7.1.1 Kesimpulan Analitis

Hasil analisis menunjukkan bahwa fenomena *financial leakage* nyata terjadi dalam dataset, yang ditandai oleh dominasi transaksi bernilai kecil. Sebanyak 78,4% dari total 6.573 transaksi memiliki nominal di bawah Rp100.000, dengan akumulasi pengeluaran mencapai Rp328.752.967.

Fenomena *micro-spending* ini paling menonjol pada persona anak kos dan mahasiswa. Pada kedua segmen tersebut, transaksi kecil di kategori **Makanan & Minuman** serta **Transportasi** menghasilkan total pengeluaran sebesar **Rp30.591.431** dari **997 transaksi**, menunjukkan bahwa pengeluaran kecil yang dilakukan secara berulang dapat memberikan dampak signifikan terhadap kemampuan menabung pengguna.

7.1.2 Dominasi Kategori, Pola Tren Temporal, dan Karakteristik Persona

Analisis menunjukkan bahwa 60,5% dari total pengeluaran terkonsentrasi pada tiga kategori utama, yaitu Kebutuhan Rumah (24,2%), Transport (19,3%), dan Belanja (17,0%). Sementara itu, kategori Makanan & Minuman memiliki frekuensi transaksi tertinggi dengan 1.474 transaksi.

Dari sisi temporal, ditemukan pola *seasonality* yang konsisten, di mana sebagian besar persona mengalami peningkatan pengeluaran pada minggu pertama setiap bulan, menjadikannya periode yang paling rentan terhadap pengeluaran berlebih.

Analisis berdasarkan persona menunjukkan karakteristik yang berbeda:

- **Ibu Rumah Tangga:** Memiliki total pengeluaran dan volume transaksi tertinggi.
- **Mahasiswa:** Memiliki total pengeluaran terendah dengan fokus utama pada kategori Transport.
- **Anak Kos:** Memiliki konsentrasi pengeluaran tertinggi pada kategori Kebutuhan Rumah.
- **Anak Sultan:** Pengeluarannya didominasi oleh kategori Belanja dan Hiburan.

7.1.3 Pergeseran ke Pembayaran Digital dan Efek *Payment Decoupling*

Mayoritas metode pembayaran telah bergeser secara masif ke instrumen nontunai, yang didominasi oleh QRIS, GoPay, dan Debit Card. Pada kelompok pengguna muda, QRIS dan GoPay menjadi instrumen utama yang paling sering digunakan untuk bertransaksi di *lifestyle merchants* seperti Miniso dan Gacoan. Kemudahan akses tanpa batas (*seamless payment*) ini memicu efek psikologis *payment decoupling*, yang mengaburkan kesadaran menakar saldo harian dan mendorong perilaku konsumsi impulsif karena hilangnya beban psikologis saat melepaskan uang fisik (*the pain of paying*).

7.2 Kesimpulan Analitis

Untuk mentransformasi aplikasi Wallee dari sekadar alat pencatat pasif (*tracking*) menjadi sistem pencegah kebocoran finansial yang proaktif (*predicting & preventing*), direkomendasikan empat *action items* berbasis fitur berikut:

Action Item #1 — Dashboard Monitoring untuk Mitigasi *Micro-Spending*

- **Implementasi Fitur:** Menyediakan dashboard khusus untuk memantau pengeluaran di bawah **Rp100.000**, yang mencakup kategori pengeluaran utama per bulan, tren frekuensi transaksi harian, persentase kontribusi pengeluaran mikro terhadap total anggaran, serta pemantauan kategori dengan frekuensi tinggi seperti **Makanan & Minuman**.
- **Justifikasi:** Membantu pengguna mengidentifikasi akumulasi pengeluaran kecil yang sering tidak disadari, tetapi dapat memberikan dampak signifikan terhadap kemampuan menabung.

Action Item #2 — *Predictive Alert & Financial Forecasting* di Periode Kritis

- **Implementasi Fitur:** Memanfaatkan model *forecasting* untuk memproyeksikan total pengeluaran hingga akhir bulan. Sistem juga memberikan notifikasi peringatan dini pada minggu pertama setiap bulan ketika risiko pengeluaran berlebih mulai meningkat.
- **Contoh Notifikasi:** *"Berdasarkan pola pengeluaran saat ini, total pengeluaran bulan ini diproyeksikan meningkat 18% dibandingkan bulan sebelumnya dan berpotensi melampaui anggaran transportasi."*
- **Justifikasi:** Membantu pengguna mengantisipasi potensi pembengkakan pengeluaran sejak dini sehingga dapat mengambil tindakan pengendalian sebelum anggaran terlampaui.

Action Item #3 — *Early Warning System* Deteksi Anomali Transaksi

- **Implementasi Fitur:** Menerapkan deteksi anomali berbasis deviasi statistik untuk mengidentifikasi transaksi yang nilainya jauh melebihi pola pengeluaran historis pengguna.
- **Contoh Notifikasi:** *"Transaksi sebesar Rp1.000.000 terdeteksi 4 kali lebih tinggi dibandingkan rata-rata transaksi harian Anda. Apakah pengeluaran ini termasuk kebutuhan prioritas?"*
- **Justifikasi:** Membantu pengguna mengenali pengeluaran yang tidak biasa dan mendorong evaluasi sebelum keputusan finansial berdampak lebih besar.

Action Item #4 — Sistem Anggaran Berbasis Persona

- **Implementasi Fitur:** Menerapkan sistem anggaran yang disesuaikan dengan karakteristik setiap persona. Sebagai contoh, fokus pengendalian pada kategori **Transport** untuk Mahasiswa, Kebutuhan Rumah untuk Anak Kos, serta Belanja dan Hiburan untuk Anak Sultan.
- **Justifikasi:** Memungkinkan rekomendasi anggaran yang lebih relevan dan tepat sasaran sesuai pola pengeluaran masing-masing pengguna.

7.3 Kesimpulan Umum

Wallee sebagai sistem analitik keuangan personal berbasis Data Science berhasil mengimplementasikan seluruh tahapan *Data Science Lifecycle*, mulai dari identifikasi masalah, pengumpulan dan pembersihan data, *exploratory data analysis* (EDA), *feature engineering*, hingga pengembangan model *forecasting*, *anomaly detection*, dan penyajian hasil melalui dashboard interaktif.

Hasil analisis menunjukkan bahwa **78,4% dari 6.573 transaksi** bernilai di bawah **Rp100.000** dan menyumbang **48,2%** dari total pengeluaran. Selain itu, **66,8%** transaksi dilakukan melalui metode pembayaran digital, sementara **4,4%** transaksi teridentifikasi sebagai *outlier*. Temuan ini memberikan dasar yang kuat untuk pengembangan fitur pengelolaan keuangan yang lebih proaktif.

Melalui integrasi teknik *time-series forecasting*, *anomaly detection*, dan rekomendasi berbasis data, Wallee tidak hanya berfungsi sebagai alat pencatatan keuangan, tetapi juga sebagai sistem yang membantu pengguna memprediksi dan mengendalikan pengeluaran. Dengan pendekatan tersebut, Wallee memiliki potensi untuk mendukung pengambilan keputusan finansial yang lebih baik serta mendorong kebiasaan keuangan yang lebih sehat dan berkelanjutan.